

Classificação Automática de Doenças em Plantas a partir de Imagens de Folhas utilizando Redes Neurais Convolucionais

Julio Cezar da Cunha

RA: 111739

Curso de Engenharia de Computação

Fundação Hermínio Ometto (FHO)

Email: juliocezar@alunos.fho.edu.br

Resumo—A agricultura moderna enfrenta desafios significativos relacionados à detecção precoce de doenças em plantas, que afetam diretamente a produtividade e a qualidade das colheitas. Este trabalho propõe o desenvolvimento de um modelo de classificação automática de doenças foliares utilizando redes neurais convolucionais (CNNs). O estudo emprega técnicas de pré-processamento de imagens, aprendizado profundo e comparação entre diferentes arquiteturas para identificar a mais eficiente, sendo o modelo VGG16 com Transfer Learning o que apresentou o resultado mais satisfatório na fase de teste. O objetivo é oferecer um sistema computacional que auxilie agricultores e pesquisadores na tomada de decisões e no manejo sustentável de culturas, promovendo a agricultura de precisão e reduzindo perdas econômicas.

Index Terms—Redes neurais convolucionais, Visão computacional, Agricultura de precisão, Plant Village, Transfer Learning.

I. INTRODUÇÃO E ESCOPO

A. Definição do Problema e Relevância

A agricultura sofre perdas significativas devido a doenças foliares, o que compromete a qualidade e o rendimento das colheitas. O diagnóstico tradicional, baseado em inspeção visual, é demorado e suscetível a erros humanos. A utilização de redes neurais convolucionais (CNNs) surge como uma solução para automatizar a identificação de doenças em folhas de plantas, favorecendo a detecção precoce e o apoio à tomada de decisão agrícola. O **Transfer Learning** aplicado a arquiteturas pré-treinadas (como VGG16) tem demonstrado ser uma técnica altamente eficaz para este fim [1], [2].

B. Objetivos

O **Objetivo geral** é: Desenvolver e avaliar um classificador automático baseado em redes neurais convolucionais para identificar doenças foliares em plantas.

Os **Objetivos específicos** incluem: 1) Construir um pipeline de pré-processamento de imagens robusto, incluindo normalização e *data augmentation*; 2) Implementar e comparar o desempenho entre uma CNN customizada e um modelo de *Transfer Learning* (VGG16); 3) Avaliar o modelo final em métricas de desempenho e em um conjunto de imagens externas de campo para verificar a capacidade de generalização.

C. Escopo do Projeto

Este trabalho utiliza o *dataset* público **Plant Village**. Foram comparadas duas metodologias: uma **CNN Customizada** e o **VGG16** com camadas base congeladas. A **validação final** do modelo VGG16, que obteve o melhor desempenho, foi complementada com um conjunto de **imagens de teste de campo externas** (*novas_imagens*), fornecidas por uma colega de Agronomia, para avaliar o desempenho em condições não-curadas. A divisão dos dados seguiu o padrão 70% (treino), 15% (validação) e 15% (teste), conforme o script `organiza_plantvillage.py`.

II. TRABALHOS RELACIONADOS

Diversos estudos [1], [2], [3] têm validado o uso de CNNs pré-treinadas para detecção de doenças em plantas, alcançando acurácias superiores a 90% no *dataset* PlantVillage. A comparação entre modelos como AlexNet, VGG e GoogLeNet [2] destaca a eficácia do *Transfer Learning* em reduzir o tempo de treinamento, um fator crucial no ambiente de *hardware* restrito (CPU) utilizado neste projeto. Outras pesquisas [4] focam na otimização para implantação em dispositivos móveis, um possível trabalho futuro.

III. METODOLOGIA

A. Preparo e Aumento de Dados

As imagens do Plant Village foram redimensionadas para o padrão de 224×224 pixels e normalizadas ($1/255$). O **aumento de dados** (*data augmentation*), implementado via `ImageDataGenerator` (com rotação, *zoom*, *shift* e *flip*), foi utilizado para aumentar a robustez do modelo, simulando variações encontradas em campo.

B. Modelagem e Treinamento

Foram testadas duas arquiteturas principais:

- 1) **CNN Customizada** (`plant_disease_complete.py`): Uma rede superficial com três camadas convolucionais (32, 64, 128 filtros) e camadas densas, treinada do zero.
- 2) **Transfer Learning** (`plant_disease_complete_vgg16.py`): A rede VGG16 foi carregada com pesos do ImageNet

(`include_top=False`). As camadas convolucionais foram **congeladas**, agindo como extratoras de características. Apenas um novo *head* de classificação (*Dense 512 + softmax*) foi treinado. Esta abordagem, embora tenha sido **computacionalmente cara em CPU** (30 horas para 20 épocas), foi mantida para demonstrar sua alta acurácia.

O treinamento foi executado com o otimizador *Adam* e a função de perda *categorical cross-entropy*, utilizando *callbacks* `ModelCheckpoint` e `EarlyStopping`.

C. Avaliação

Os modelos foram avaliados com **acurácia, precisão, recall** e F1-score. O *script* `testar_novas_imagens.py` foi crucial para testar o modelo VGG16 final em imagens de campo não pertencentes ao Plant Village, verificando a capacidade de generalização em cenários práticos.

IV. CONCLUSÃO

O modelo **VGG16** utilizando *Transfer Learning* demonstrou ser a arquitetura mais eficaz para a classificação de doenças de plantas, atingindo resultados satisfatórios tanto no conjunto de teste do Plant Village quanto nas imagens externas de campo. A validação em dados de campo confere validade e potencial de aplicabilidade ao sistema desenvolvido. O principal desafio encontrado foi a restrição de **hardware** (CPU), que impactou o tempo de treinamento. Como **trabalhos futuros**, planeja-se o *fine-tuning* do VGG16 em ambiente GPU para otimização de performance e a exploração de modelos leves para *deploy* móvel.

REFERÊNCIAS

REFERÊNCIAS

- [1] S. P. Mohanty, D. P. Hughes and M. Salathé, "Using deep learning for image-based plant disease detection," *Frontiers in Plant Science*, vol. 7, p. 1419, 2016.
- [2] K. P. Ferentinos, "Deep learning models for plant disease detection and diagnosis," *Computers and Electronics in Agriculture*, vol. 145, pp. 311-318, 2018.
- [3] E. C. Too, Y. Li, S. Njuki and Y. Liu, "A comparative study of fine-tuning deep learning models for plant disease identification," *Computers and Electronics in Agriculture*, vol. 161, pp. 272-279, 2019.
- [4] K. Zhang, Q. Wu, A. Liu and X. Meng, "Automatic identification of plant leaf diseases based on improved convolutional neural network," *IEEE Access*, vol. 8, pp. 4328-4336, 2020.